La economía del entretenimiento: Netflix y tendencias globales

Fase 1 – Análisis | Documento de justificación

Integrante: Emilio Oropeza (230300762)

1. Introducción

En este proyecto vamos a hacer un dashboard en React con el dataset **Netflix Movies and TV Shows** de Kaggle. La idea es ver qué tipo de contenido tiene Netflix, de qué países viene, cómo ha cambiado por año y qué géneros y directores aparecen más. En esta primera fase nos enfocamos en entender el problema, a quién va dirigido el dashboard y cómo vamos a preparar los datos antes de programar.

2. Análisis de la audiencia

¿Quién lo va a usar?

- Gerentes y equipos de estrategia de contenido de una plataforma de streaming (o alguien que quiera competir con Netflix).
- Analistas de negocio y marketing que estudian el mercado del entretenimiento digital.
- Estudiantes o público en general interesado en tendencias de series y películas.

¿Qué decisiones van a tomar?

- En qué países o regiones conviene invertir o producir más contenido.
- Qué géneros están creciendo y cuáles ya están muy saturados.
- Si conviene apostar más por películas o por series.
- Con qué directores o tipo de producciones vale la pena trabajar.

Nivel de detalle: la audiencia principal son personas que deciden, así que necesitan ver la información resumida (totales, tops y tendencias) y no título por título. Aun así vamos a poner filtros por año, país y tipo de contenido para que puedan bajar un poco más al detalle si quieren.

3. Definición de objetivos

Objetivo: visualizar las tendencias del catálogo de Netflix por año, país, género y tipo de contenido para entender cómo ha cambiado la producción del entretenimiento digital y cómo varían los gustos por región.

¿Qué problema resuelve? El dataset tiene miles de títulos en una tabla y así es muy difícil ver patrones. El dashboard junta todo en indicadores y gráficas para que se entienda rápido qué está pasando sin tener que revisar el CSV.

KPIs e indicadores:

KPI / Gráfica	Qué muestra	Para qué sirve

Títulos por país (mapa de calor)	Cantidad de títulos producidos por cada país	Ver qué regiones dominan el catálogo
Lanzamientos por año (gráfico temporal)	Títulos por año de estreno y por año agregado a Netflix	Ver el crecimiento y los cambios en el tiempo
Top 5 géneros (nube de palabras)	Géneros que más se repiten	Saber qué tipo de contenido predomina
Top 5 directores	Directores con más títulos	Identificar a los más productivos
Películas vs series (gráfico circular)	Porcentaje de cada tipo de contenido	Ver hacia dónde se inclina el catálogo

4. Preprocesamiento de datos

4.1 Identificación y entendimiento de variables

El dataset viene en un CSV (netflix_titles.csv) con cerca de 8,800 registros. Cada fila es un título. Las variables son:

Variable	Tipo	Significado	¿La usamos?
show_id	Texto	ID único del título	Sí (llave)
type	Texto	Movie o TV Show	Sí
title	Texto	Nombre del título	Sí
director	Texto	Director(es), separados por coma	Sí
cast	Texto	Actores, separados por coma	No (no hay KPI de actores)
country	Texto	País(es) de producción, separados por coma	Sí
date_added	Texto (fecha)	Fecha en que se agregó a Netflix	Sí
release_year	Número	Año de estreno original	Sí
rating	Texto	Clasificación (TV-MA, PG-13, etc.)	Sí (filtro)
duration	Texto	Minutos (películas) o temporadas (series)	Sí
listed_in	Texto	Géneros, separados por coma	Sí
description	Texto	Sinopsis	No

4.2 Limpieza de datos

- **Valores nulos:** director, cast y country tienen muchos vacíos. No borramos esas filas porque perderíamos muchos títulos; los llenamos con "Desconocido" y al sacar los tops los dejamos fuera. Los pocos nulos de date_added, rating y duration se revisan a mano o se eliminan porque son muy pocos.

- **Fechas:** date_added viene como texto (ej. "September 25, 2021") y a veces con espacios al inicio. Le quitamos los espacios y la convertimos a tipo fecha.
- **Errores:** hay algunos registros donde la duración quedó en la columna rating (ej. "74 min"). Los pasamos a duration y dejamos rating vacío.
- **Géneros, países y directores múltiples:** vienen juntos en una celda separados por coma. Los separamos para que cada uno cuente por separado.
- **Duplicados y texto:** revisamos que no haya show_id repetidos y quitamos espacios extra en todos los campos de texto.

Columnas derivadas:

- year_added y month_added (sacadas de date_added).
- duration_value y duration_unit (separar "90 min" en 90 y min, o "2 Seasons" en 2 y Seasons).
- main_country (el primer país de la lista, para el mapa).

4.3 Manejo de valores atípicos

- **release_year:** hay títulos muy viejos (desde los años 20). No son errores, son clásicos reales, así que se quedan, pero en el gráfico temporal ponemos un filtro de rango de años para que no se vea aplastado.
- **Duración:** usamos el método del rango intercuartílico (IQR) para ubicar películas muy cortas o muy largas. Si son reales (cortos o especiales) se quedan; si son errores de captura se corrigen o se eliminan.
- **Año agregado menor al de estreno:** si date_added es antes que release_year, lo marcamos como inconsistencia y lo revisamos.
- **Regla general:** preferimos ajustar o filtrar en vez de borrar, porque cada título es un dato real del catálogo.

4.4 Integración de datos

Elegimos **PostgreSQL** (en Supabase, que es gratis y se conecta fácil con Vercel). Es una base relacional y nos sirve para separar los campos que traen varios valores. El proceso es:

1. Descargar el CSV de Kaggle.
2. Limpiarlo con un script en Python (pandas) aplicando todo lo de los puntos 4.2 y 4.3.
3. Cargar los datos limpios a PostgreSQL.
4. React consulta los datos ya resumidos para pintar las gráficas.

Tablas:

Tabla	Campos principales
titles	show_id (PK), type, title, release_year, date_added, year_added, rating, duration_value, duration_unit, main_country
title_country	show_id (FK), country
title_genre	show_id (FK), genre

title_director	show_id (FK), director

Así un título puede tener varios países, géneros o directores, y es fácil contar con un GROUP BY.

5. Selección del tipo de dashboard

Escogimos un dashboard **estratégico**.

- Los datos son históricos (desde hace décadas hasta 2021) y no cambian en tiempo real, así que un dashboard operativo no tiene sentido.
- Lo que queremos ver son tendencias a largo plazo: crecimiento por año, países y géneros que dominan, películas vs series.
- La audiencia principal son personas que toman decisiones grandes (en qué invertir, qué producir, en qué mercados entrar), que es justo para lo que sirve un dashboard estratégico.
- No es táctico porque no estamos midiendo el rendimiento de un equipo o una campaña en un periodo corto.

6. Conclusión

Con esta fase ya tenemos claro para quién es el dashboard, qué problema resuelve, qué datos vamos a usar y cómo los vamos a limpiar y guardar. Elegimos un dashboard estratégico porque lo que importa es ver las tendencias globales del entretenimiento digital y cómo cambian los gustos por región y por año. Con esto podemos pasar a la siguiente fase, que es el diseño y desarrollo en React.